Sistemas Operativos

Gesitón de Procesos
Multitarea y Planificación

Agenda

Agenda

Base de la Multitarea

- Los procesos pasan por fases de E/S y CPU
- Mientras un proceso espera por E/S otro podría utilizar la CPU
- El SO mantiene en memoria varios procesos activos

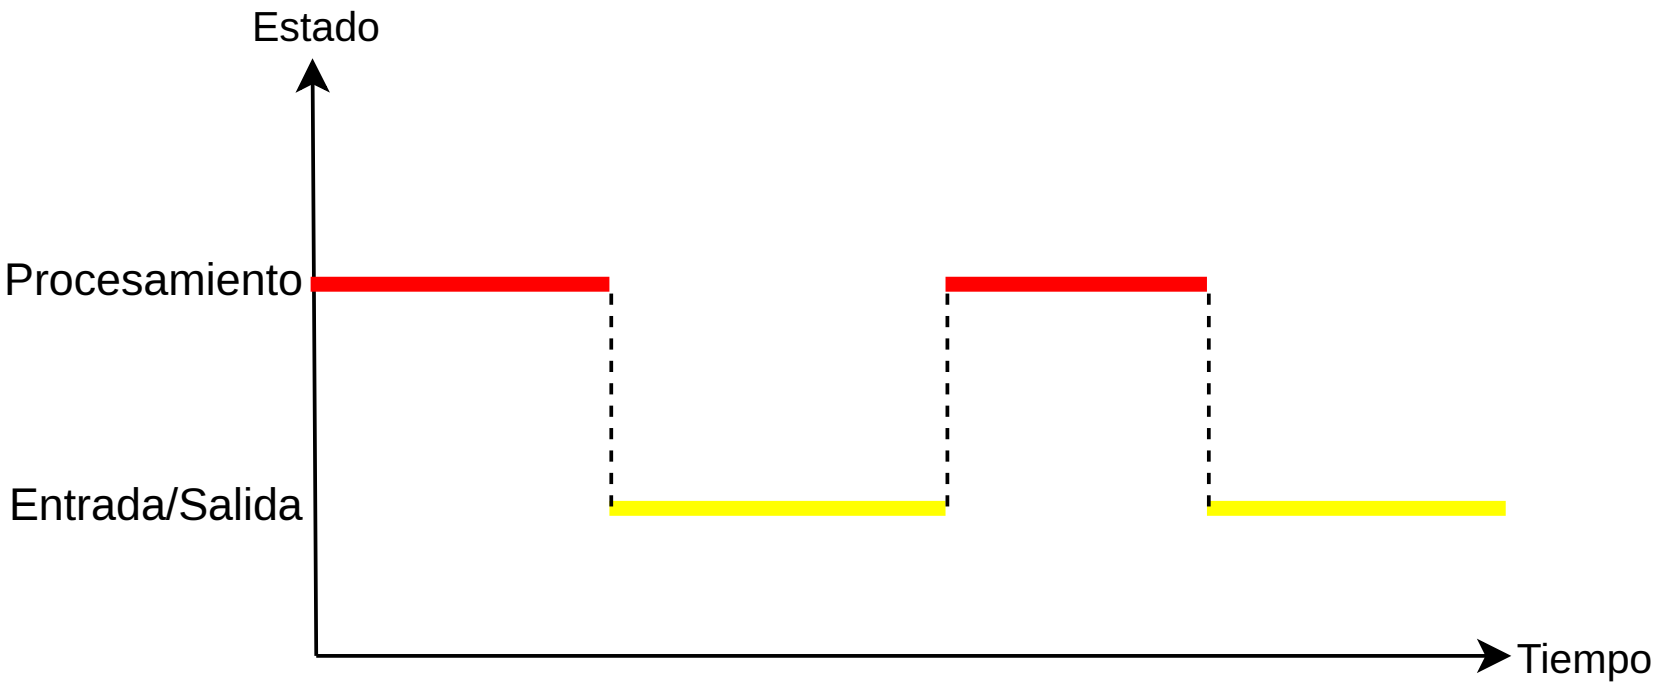

Ejecución en un sistema multitarea

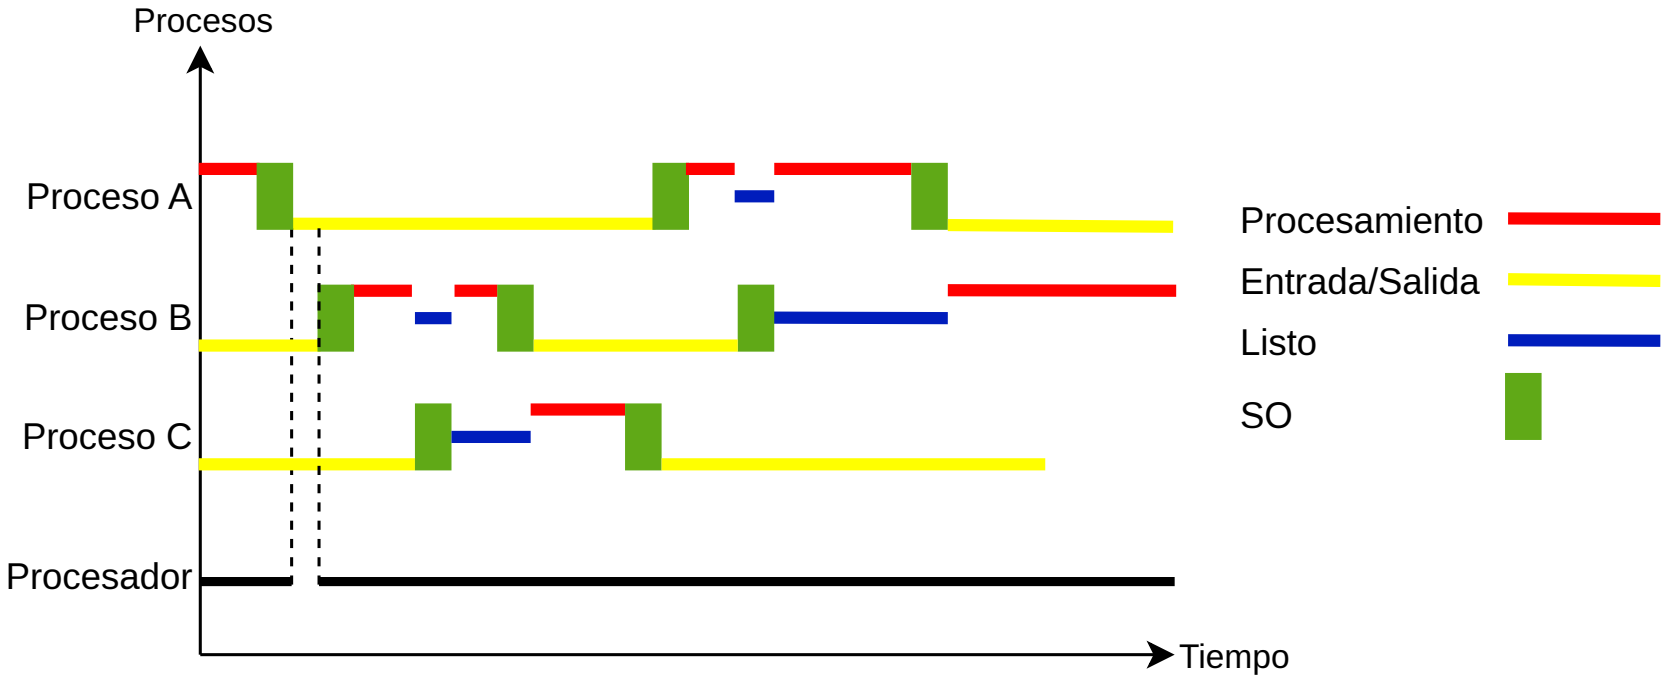

Proceso nulo o idle

Proceso que mantiene la cpu ejecutando instrucciones cuando no hay ningún otro proceso listo en el sistema. No hace nada útil. Es el menos prioritario.

Ventajas de la multitarea

- Facilita la programación, dividiendo los programas en procesos (modularidad)
- Permite el servicio interactivo simultáneo de varios usuarios de forma eficiente
- Aprovecha los tiempos que los procesos pasan esperando a que se completen sus operaciones de E/S
- Aumenta el uso de la CPU

Grado de multiprogramación

- Grado de multiprogramación: nº de procesos activos
- Aumentarlo demasiado puede degradar el rendimiento global por paginación.

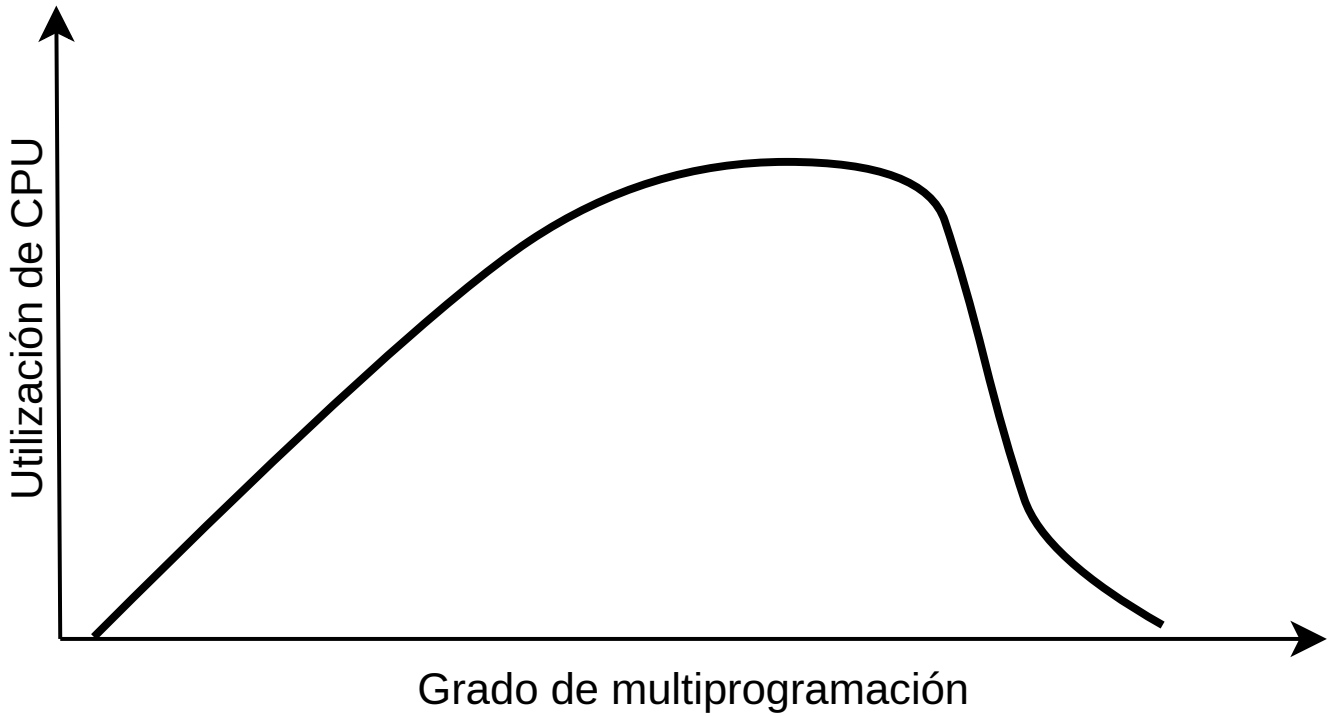

Agenda

Niveles de planificación

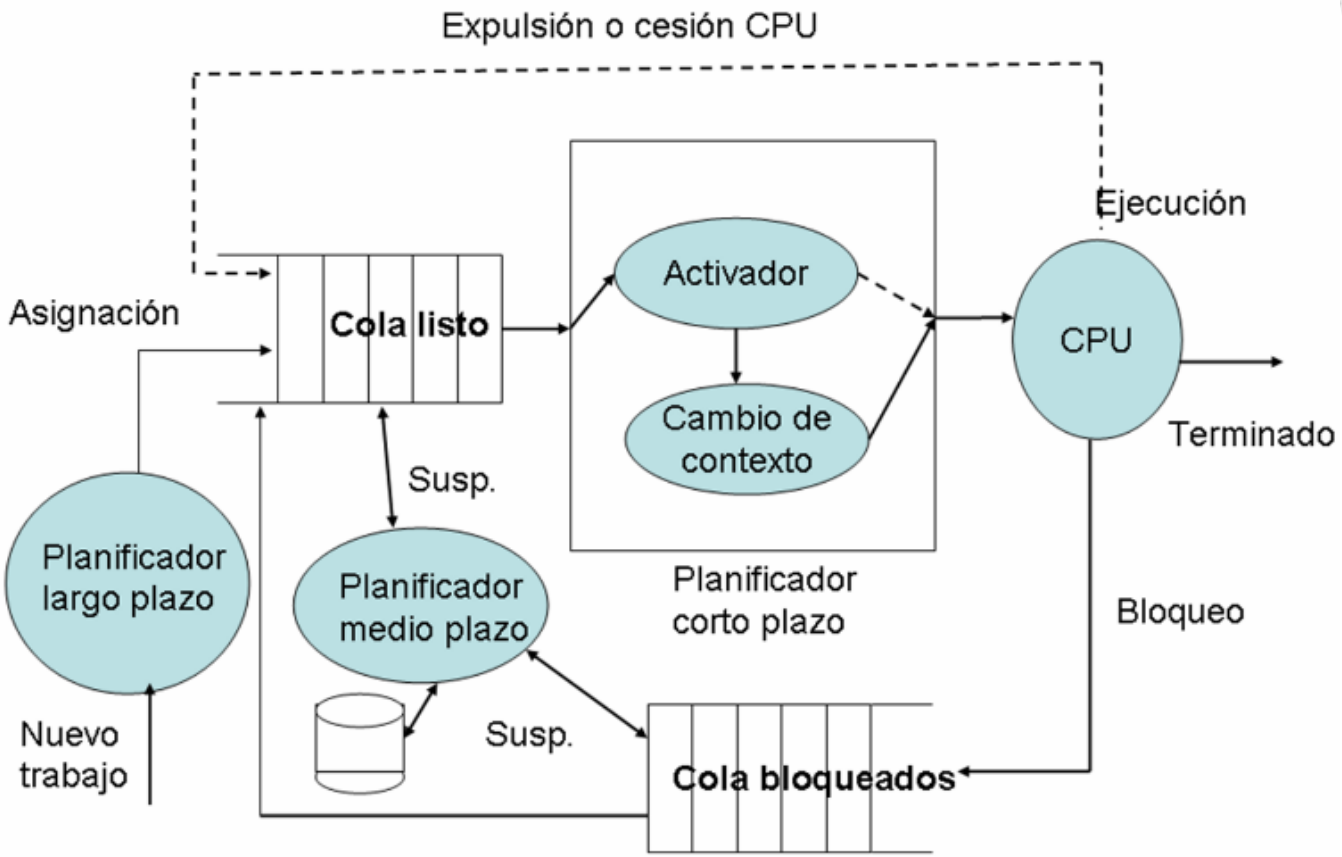

- **A largo plazo**: añadir procesos a ejecutar (batch)
- **A medio plazo**: añadir procesos a RAM
- **A corto plazo**: qué proceso tiene la CPU

Planificación a corto plazo

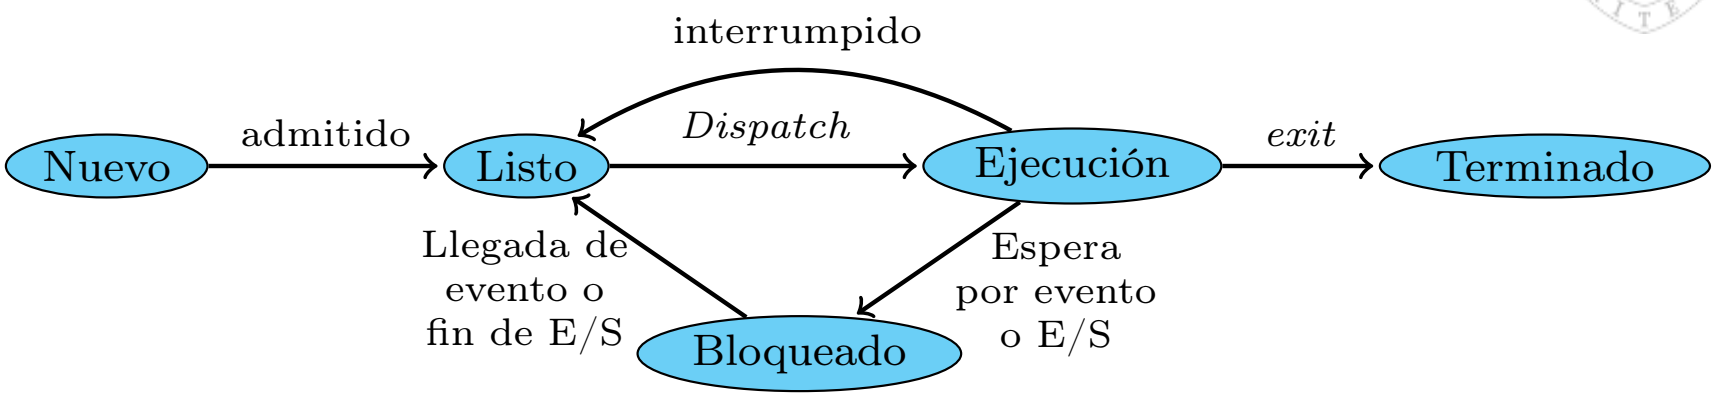

Activador o dispatcher: cede el control al siguiente proceso

- Escogido entre los hilos en estado **Listo (ready)**
- Depende de la **política de planificación**
- Cambiar de proceso implica un cambio de contexto

Agenda

Excepciones/Interrupciones

El SO siempre entra a través de una excepción/interrupción

- El tratamiento de la interrupción supone:
  1. Detener la ejecución de instrucciones (programa actual)
  2. Cambiar a *modo privilegiado*
  3. Salvar el estado arquitectónico (en la pila de kernel del proceso)
  4. Ejecutar la rutina de tratamiento de excepción/interrupción
- La RTI
  - es código del SO
  - es ejecutada en el contexto del proceso activo
  - finaliza con un proceso de retorno de interrupción que restaura el contexto arquitectónico
- Algunas interrupciones y/o excepciones desencadenan la ejecución del planificador

Activación del Planificador

1. Periódicamente, en cada tick del reloj del sistema
   - El HW provee al SO de un contador programable que genera interrupciones periódicas (ticks)
   - Actualiza estadísticas para el algoritmo de planificación
   - Comprueba si le toca planificar otro proceso

Activación del Planificador

1. Periódicamente, en cada tick del reloj del sistema
   - El HW provee al SO de un contador programable que genera interrupciones periódicas (ticks)
   - Actualiza estadísticas para el algoritmo de planificación
   - Comprueba si le toca planificar otro proceso
2. Por el tratamiento de la interrupción de algún dispositivo de E/S

Activación del Planificador

1. Periódicamente, en cada tick del reloj del sistema
   - El HW provee al SO de un contador programable que genera interrupciones periódicas (ticks)
   - Actualiza estadísticas para el algoritmo de planificación
   - Comprueba si le toca planificar otro proceso
2. Por el tratamiento de la interrupción de algún dispositivo de E/S
3. Por una excepción provocada por el proceso en ejecución:
   - que lo bloquea (ej: fallo de página, llamada al sistema bloqueante)
   - que fuerza su terminación (ej: violación de segmento)
   - que termina voluntariamente el proceso en ejecución (`_exit()`)
   - que cede voluntariamente el procesador (`sched_yield()`)
   - que desbloquea o crea otro proceso (`fork`,`clone`,...)

Activación del Planificador

1. Periódicamente, en cada tick del reloj del sistema
   - El HW provee al SO de un contador programable que genera interrupciones periódicas (ticks)
   - Actualiza estadísticas para el algoritmo de planificación
   - Comprueba si le toca planificar otro proceso
2. Por el tratamiento de la interrupción de algún dispositivo de E/S
3. Por una excepción provocada por el proceso en ejecución:
   - que lo bloquea (ej: fallo de página, llamada al sistema bloqueante)
   - que fuerza su terminación (ej: violación de segmento)
   - que termina voluntariamente el proceso en ejecución (`_exit()`)
   - que cede voluntariamente el procesador (`sched_yield()`)
   - que desbloquea o crea otro proceso (`fork`,`clone`,...)
4. Porque se desbloquea un proceso más *importante* que el actual
   - Sucede realmente por alguno de los mecanismos anteriores

Cambio de Contexto

- Acciones realizadas por el SO para cambiar el proceso en ejecución en una CPU
  - Salvar el contexto del proceso saliente (registros →BCP)
  - Cambiar el estado del proceso saliente (En ejecución →Otro)
  - Configurar la MMU para el espacio de direcciones del proceso entrante:
    - Segmentos o regiones de memoria que puede usar
    - Puntero a la tabla de páginas
    - Flush de TLB
  - Cambiar el estado del proceso entrante, (Listo →En ejecución)
  - Restaurar su contexto (BCP →registros)
  - Realizar el retorno de Interrupción para continuar la ejecución del proceso (en modo usuario)
- Puede llegar a ser una operación bastante costosa

Agenda

Objetivos

- Optimizar uso de las CPUs
- Minimizar tiempo de espera
- Ofrecer reparto equitativo (justicia)
- Proporcionar grados de urgencia (prioridades)

Métricas

- Parámetros por entidad (proceso o hilo)
  - Tiempo de ejecución (*turnaround*): creación - terminación
  - Tiempo de espera: tiempo total listo y sin CPU
  - Tiempo de respuesta: creación – 1er uso de CPU
- Parámetros globales
  - Porcentaje de utilización del procesador
  - Justicia: equitatividad en el reparto de CPU
  - Productividad: número de trabajos completados por unidad de tiempo

Agenda

Algoritmos No Expropiativos

El proceso en ejecución conserva la CPU hasta que:

- se bloquea
- cede expresamente la CPU
- termina su ejecución.

First Come First Served (FCFS)

- Se planifican los procesos por orden de entrada en la cola de listos
- Muy sencillo y óptimo en uso de CPU

Proceso o Hilo	Instante de llegada	Tiempo de CPU (ms)
T0	0	5
T1	1	12
T2	2	2
T3	3	1

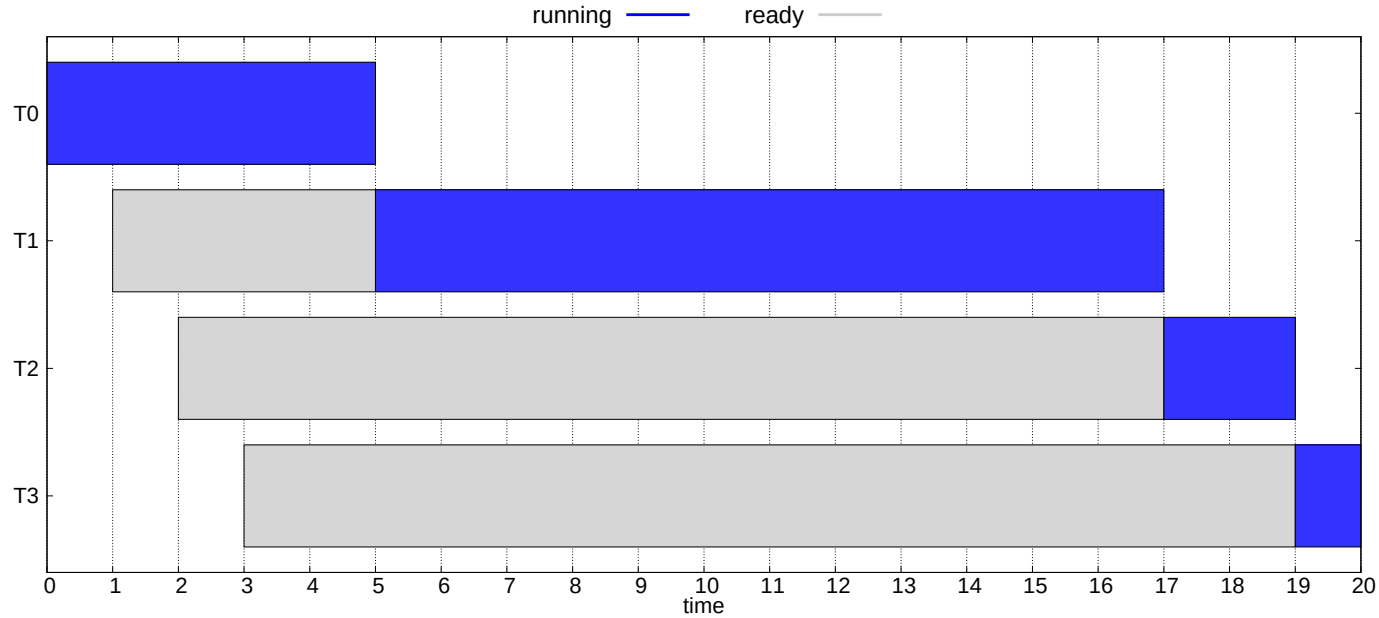

FCFS: tiempos medios altos

- Programas con E/S son encolados al final
- Programas largos afectan al sistema

Proceso o Hilo	Instante de llegada	Tiempo de CPU (ms)
T0	0	5
T1	1	12
T2	2	2
T3	3	1

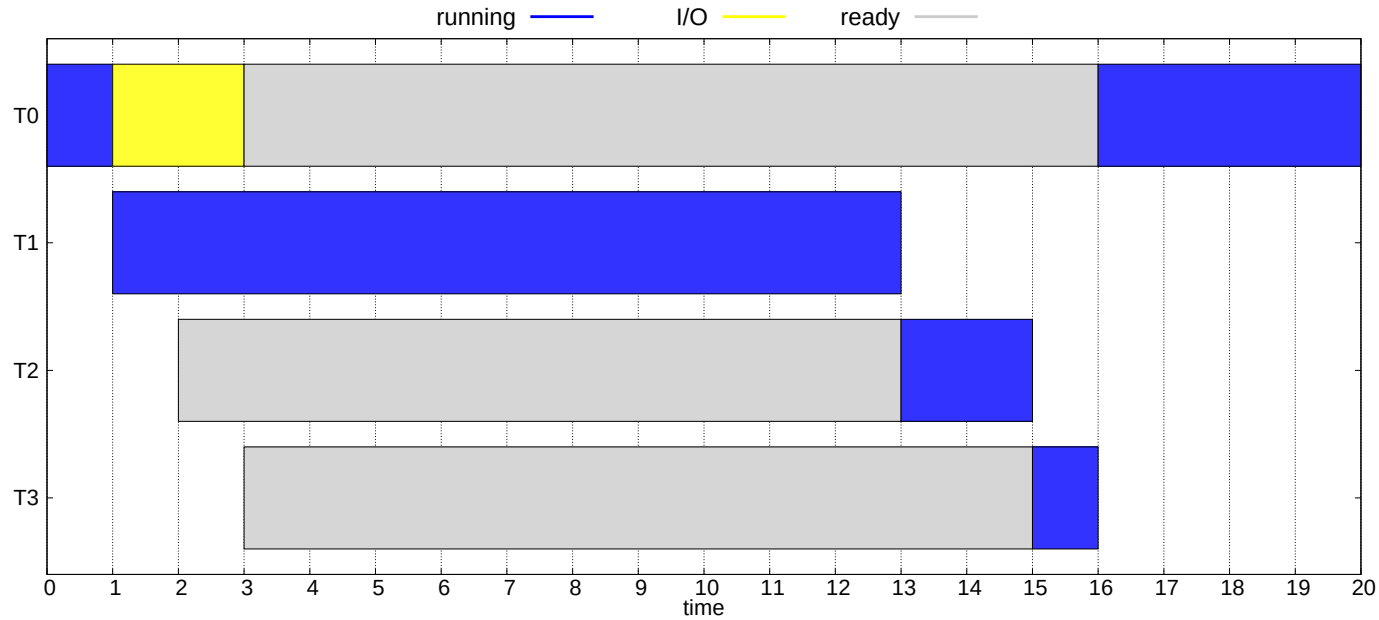

Shortest Job First (SJF)

Se planifica primero el proceso más corto

- Bueno para programas interactivos
- Necesita conocer el perfil de las tareas
- Problemas de inanición

Proceso o Hilo	Instante de llegada	Tiempo de CPU (ms)
T0	0	5
T1	1	12
T2	2	2
T3	3	1

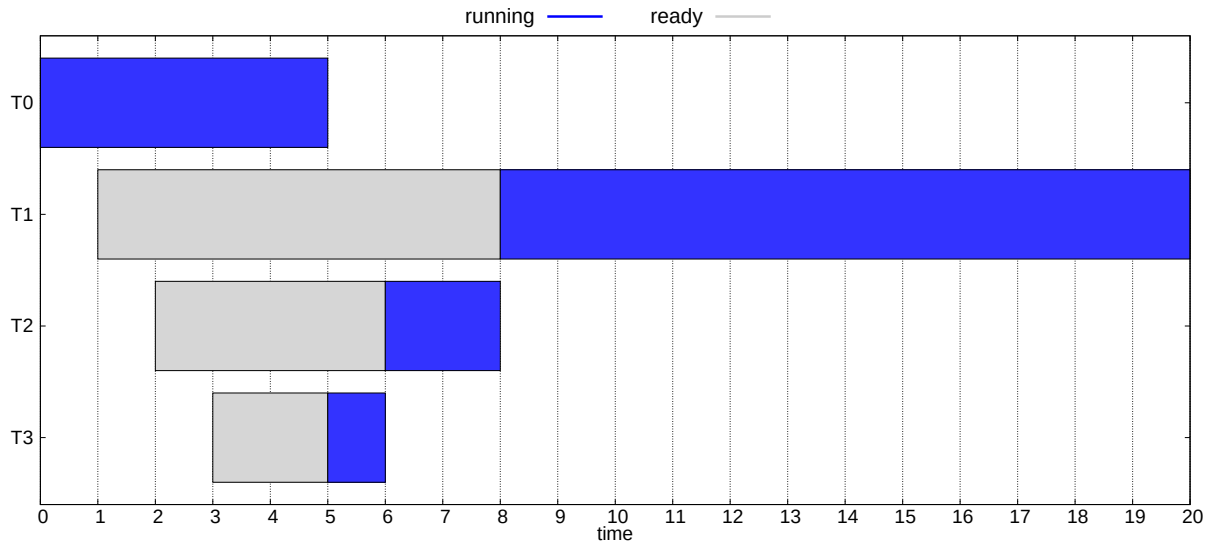

Basado en Prioridades

- Bueno para sistemas con grados de urgencia
- Problema de inanición:
  - Aumento de la prioridad con la edad

Proceso o Hilo	Instante de llegada	Tiempo de CPU (ms)	Prioridad
T0	0	5	4
T1	1	12	3
T2	2	2	1
T3	3	1	2

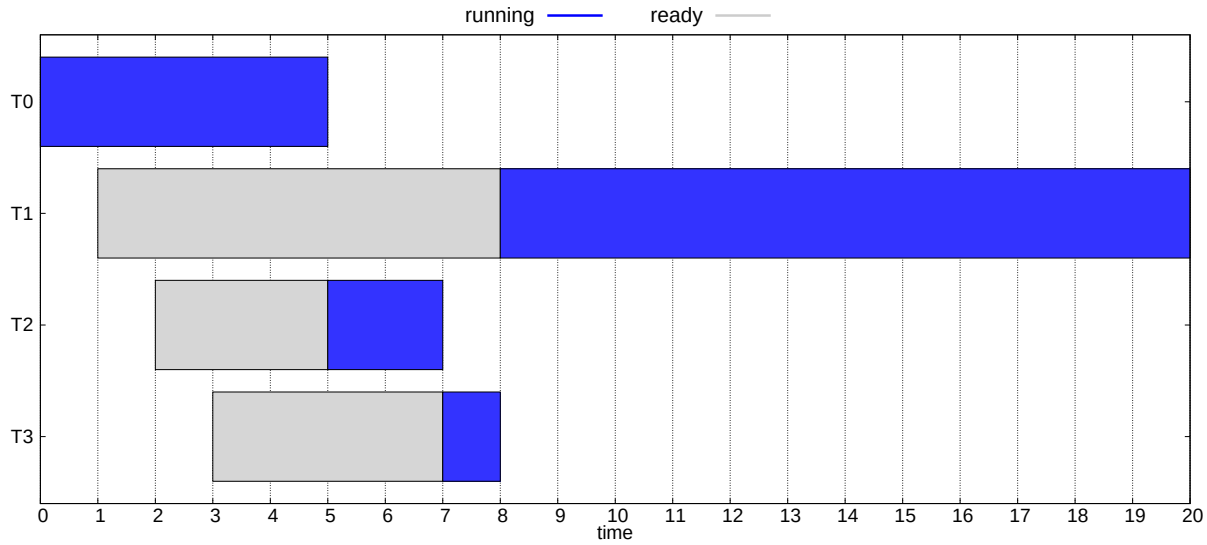

Agenda

Algoritmos Expropiativos

- Cuando el planificador lo considera pertinente, cambia el proceso/hilo que hay ejecutando por otro
  - La decisión depende del algoritmo de planificación
- Más adecuados para SO de propósito general
- Manejan bien mezclas de trabajos interactivos y trabajos intensivos en CPU

Round Robin

- FCFS + time slice
  - Asignación rotatoria de CPU
  - Se asigna un tiempo máximo de procesador que el proceso puede consumir sin ser expropiado (**time slice** o **cuanto**)
- Uso en sistemas de tiempo compartido
  - Equitativo (mejor por uid que por proceso)

Round Robin: ejemplo (I)

Cuanto: 2

Proceso o Hilo	Instante de llegada	Tiempo de CPU (ms)
T0	0	5
T1	1	12
T2	2	2
T3	3	1

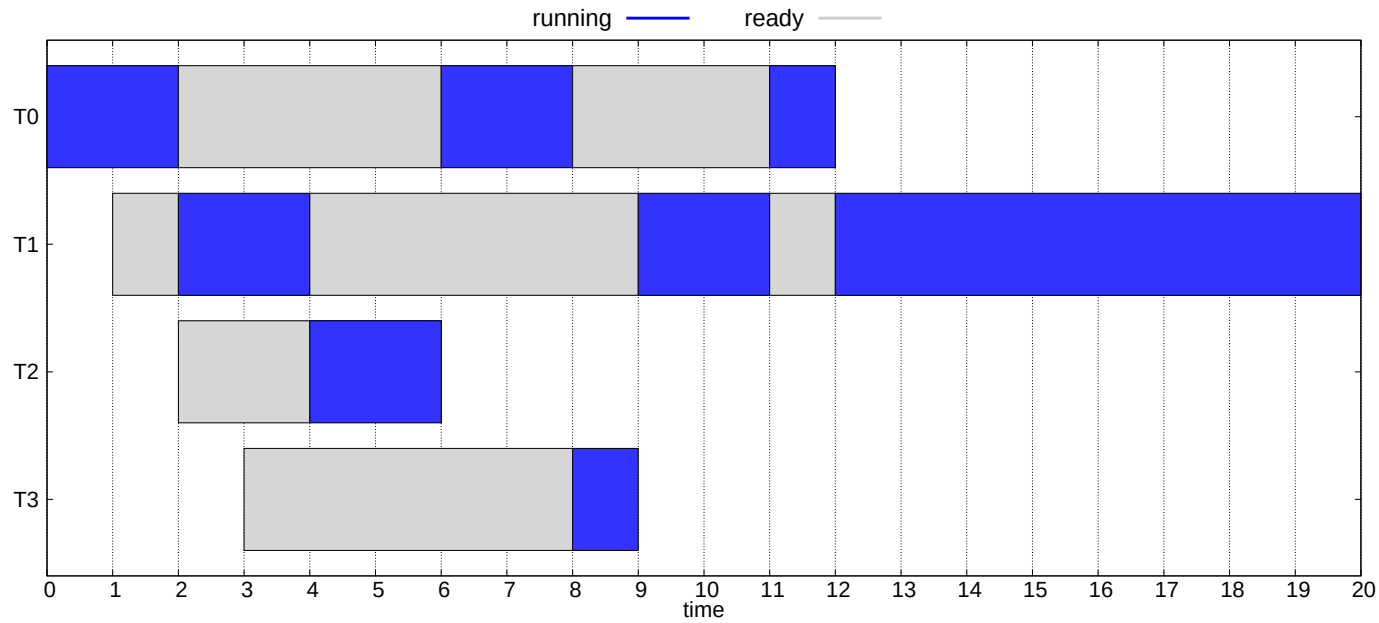

Round Robin: ejemplo (II)

Cuanto: 2

Proceso o Hilo	Instante de llegada	Tiempo de CPU (ms)
T0	0	5
T1	1	12
T2	2	2
T3	3	1

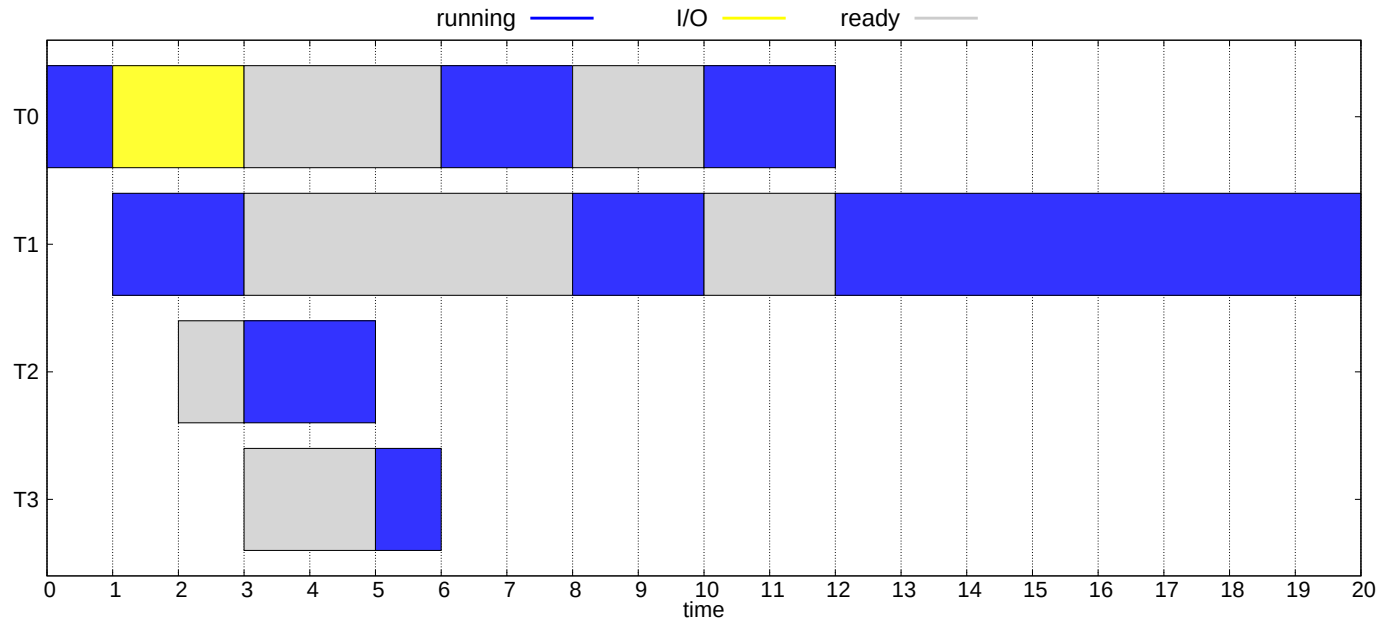

Shortest Remaining Time First (SRTF)

- SJF + time slice variable
  - Bueno para programas interactivos
  - Necesita conocer el perfil de las tareas
  - Problemas de inanición

Proceso o Hilo	Instante de llegada	Tiempo de CPU (ms)
T0	0	5
T1	1	12
T2	2	2
T3	3	1

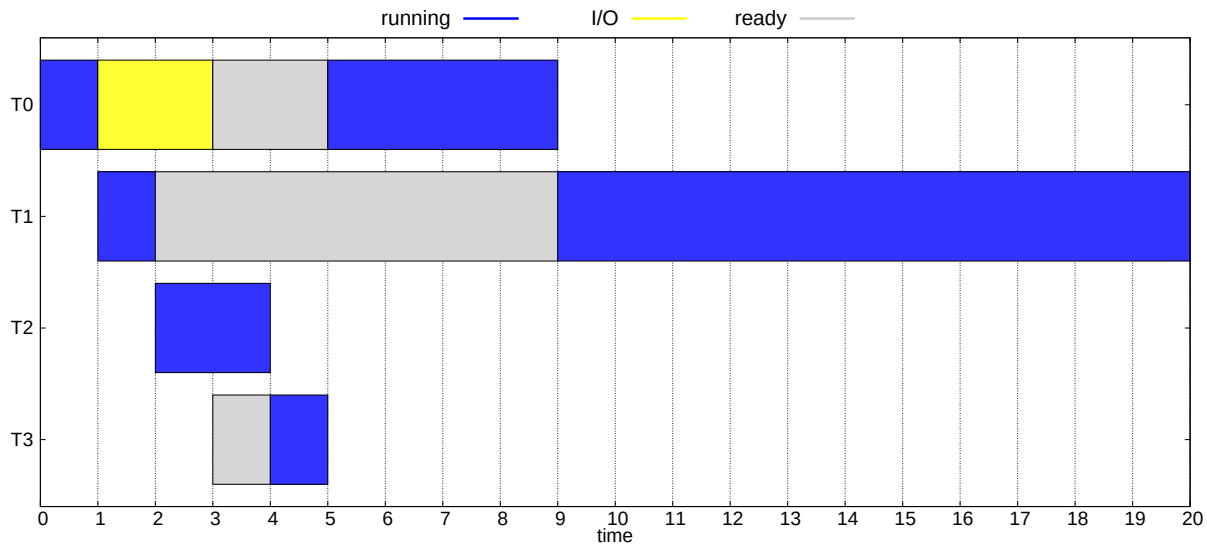

Expropiativo basado en prioridades

- Bueno para sistemas con grados de urgencia
- Problema de inanición:
  - Aumento de la prioridad con la edad

Proceso o Hilo	Instante de llegada	Tiempo de CPU (ms)	Prioridad
T0	0	5	4
T1	1	12	3
T2	2	2	1
T3	3	1	2

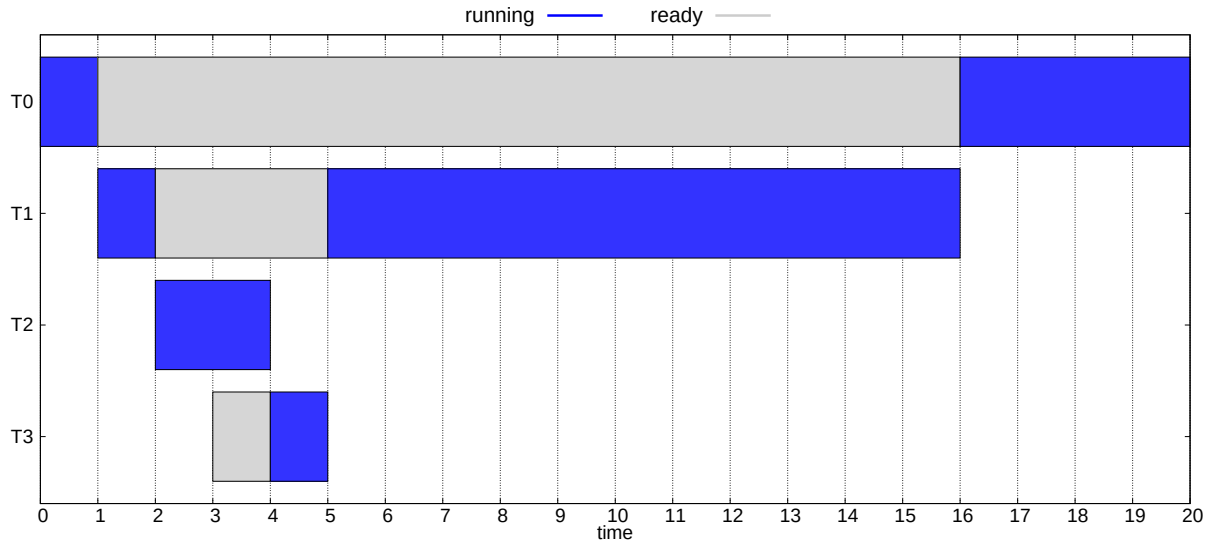

Agenda

Motivación

Colas Multinivel con Realimentación (MLFQ)

- Queremos reducir el tiempo de ejecución medio (*turnaround*)
  - Como lo hace SJF
  - Sin conocer a priory el tiempo de ejecución de cada tarea
  - El sistema debe aprender las carácterísticas de cada tarea
- Queremos reducir el tiempo de respuesta
  - Como lo hace Round Robin
  - Importante para tareas interactivas
- Objetivos contrapuestos

Reglas básicas

- Varias colas con distinto nivel de prioridad
- La prioridad de un proceso es la de la cola a la que está asignado
- Si Prioridad(A) $>$ Prioridad(B), A se ejecuta y B no
- Si Prioridad(A) $==$ Prioridad(B), se usa RR para planificar la ejecución de A & B
  - En el ejemplo:
    - A y B se alternan en uso de la CPU
    - C y D no se ejecutan

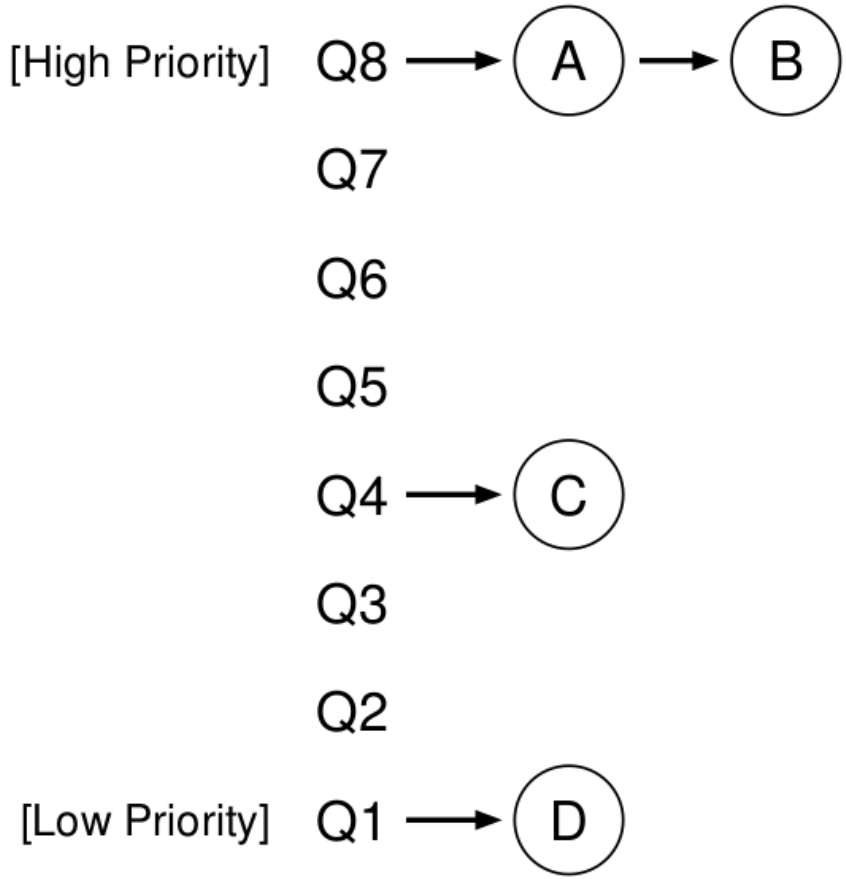

Tareas con prioridades dinámicas

- Variar la prioridad de las tareas en función de su comportamiento
  - Si un trabajo repetidamente libera la CPU bloqueándose por E/S debemos asignarle alta prioridad
  - Si una tarea repetidamente usa la CPU de forma intensiva por largos periodos de tiempo, debemos asignarle menor prioridad

El pasado para predecir el futuro

MLFQ intenta *aprender* de los procesos mientras ejecutan, usando así su *historia* para predecir su comportamiento futuro.

Asignación de prioridades: intento 1

- Cuando una tarea entra en el sistema, se le asigna la máxima prioridad (cola superior)
- Si una tarea consume su cuanto de tiempo completo mientras ejecuta, se *reduce* su prioridad (se mueve a la siguiente cola)
- Si una tarea cede la CPU antes de consumir su cuanto de tiempo, se mantiene en el *mismo* nivel de prioridad.

Ejemplo:

Un proceso de larga duración:

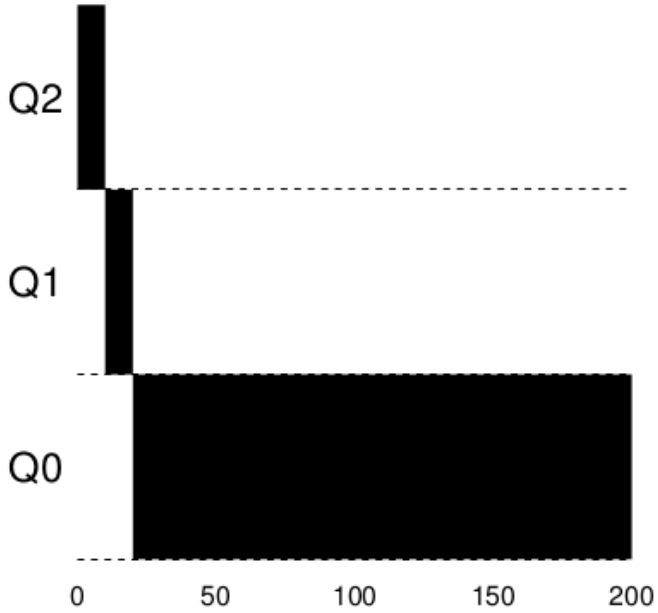

Aparece una tarea más corta:

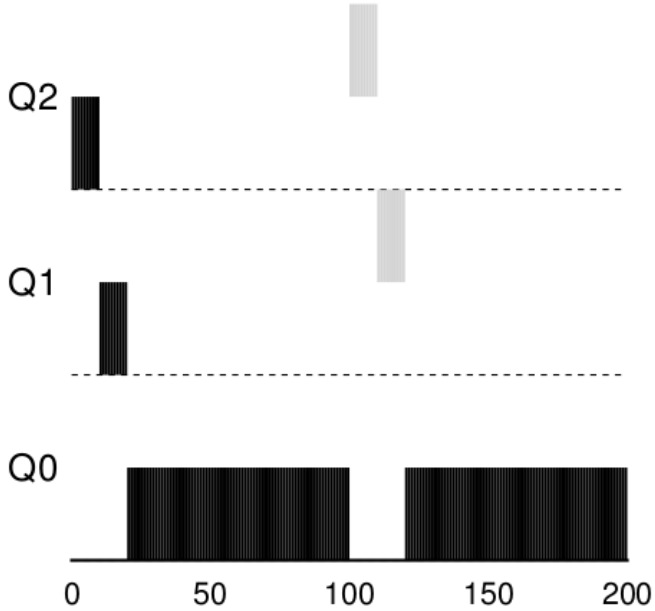

Ejemplo: tarea interactiva

- Tarea A intensiva en CPU, de larga duración (negro)
- Tarea B interactiva (gris)
  - Ráfagas cortas de CPU, menores que un cuanto, seguidas de fases de E/S

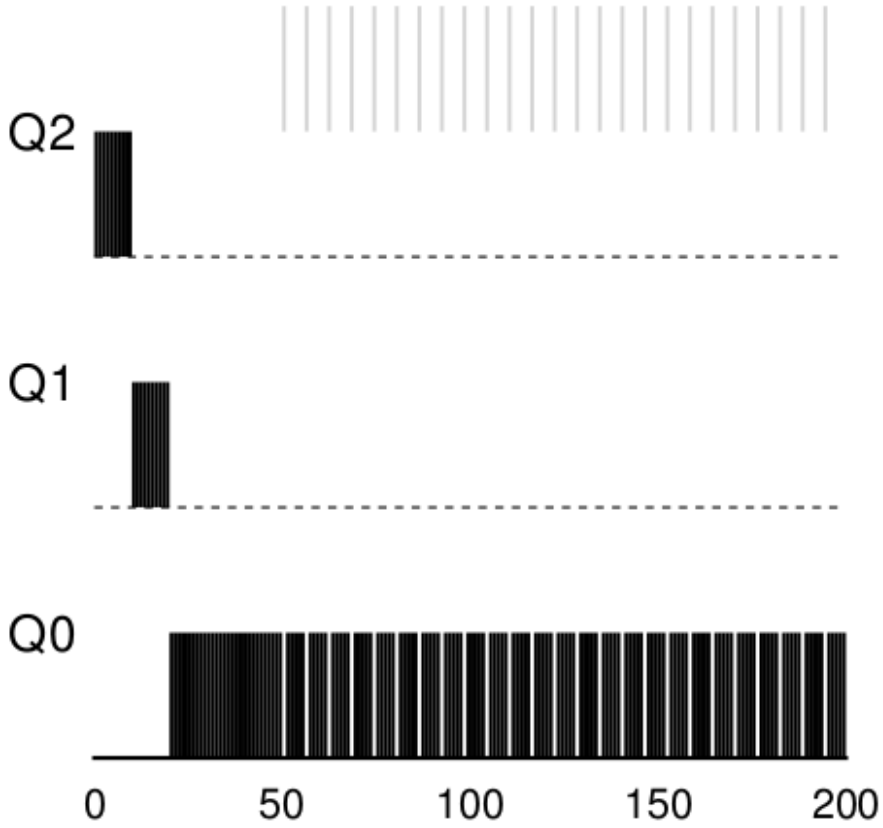

Problemas

Problemas de la estrategia vista hasta ahora:

1. Posible inanición
   - Tareas intensivas en CPU de larga duración
   - Con muchas tareas interactivas, que pueden copar la CPU
2. Posibilidad de engañar al planificador
   - Ceder cpu antes de agotar el cuanto
   - Permanecemos en máximo nivel de prioridad
   - Apurando al 99% el cuanto podemos monopolizar la CPU
3. No se adapta a los cambios de fase de las tareas
   - Una tarea intensiva en CPU que pasa a una fase interactiva se queda en el nivel menos prioritario

Evitar el problema de inanición

Priority Boost:

- Periódicamente incrementar la prioridad de todos los procesos del sistema
  - Habitualmente, con algún periodo S, todos los procesos se mueven a la cola más prioritaria

Soluciona dos problemas de golpe:

- Inanición: al pasar periódicamente a las colas más prioritarias todos los procesos podran progresar
- Adaptación a las fases de las tareas. Un cambio a una fase interactiva será detectada y atendida cuando se haga el *Priority Boost*

Priority Boost: ejemplo

- Tarea A: larga, intensiva en CPU
- Tareas B y C: interactivas, aparecen a los 100ms

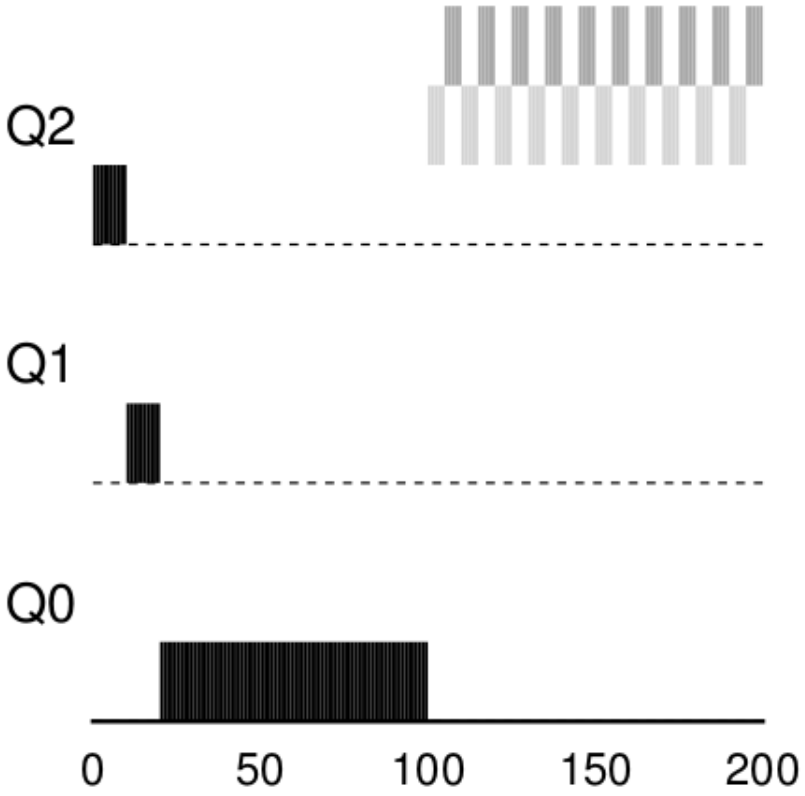

Sin Priority Boost

Inanición de A

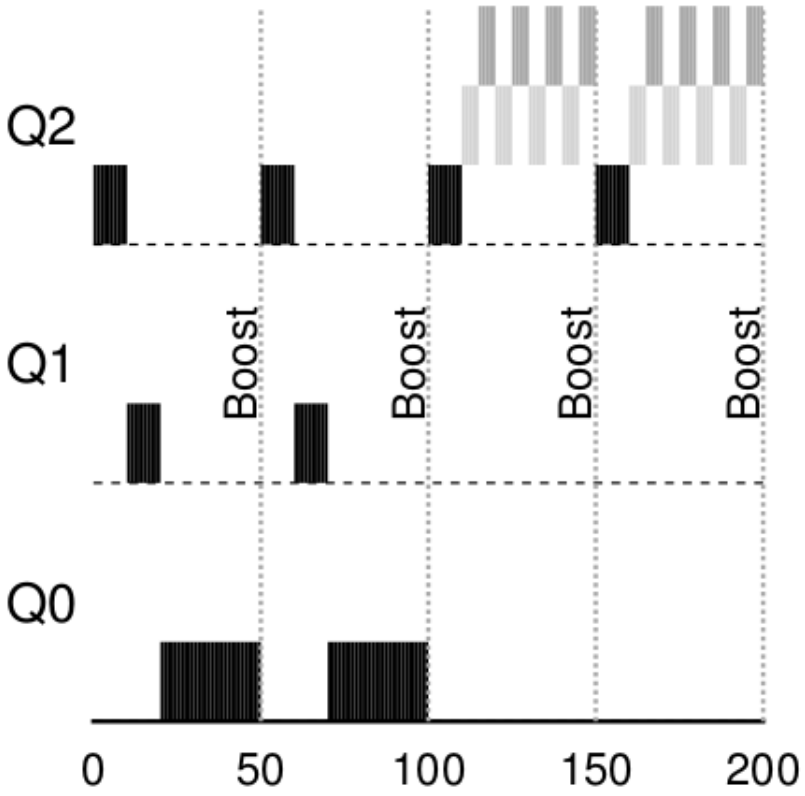

Con Priority Boost cada 50ms

A ejecuta cada 50ms

Impedir el engaño al planificador

Es necesario mejorar el *Accounting*:

- Llevar la cuenta del tiempo de CPU total de cada tarea
  - En una o varias ráfagas

Y modificar las reglas de cambio de prioridades:

- Cuando el tiempo de CPU consumido supere la asignación para ese nivel, la tarea se mueve al siguiente nivel (reduce prioridad)

Impedir engaño: ejemplo

- Tarea A: larga, intensiva en CPU
- Tarea B: trata de engañar al planificador, cediendo cpu antes de consumir el cuanto

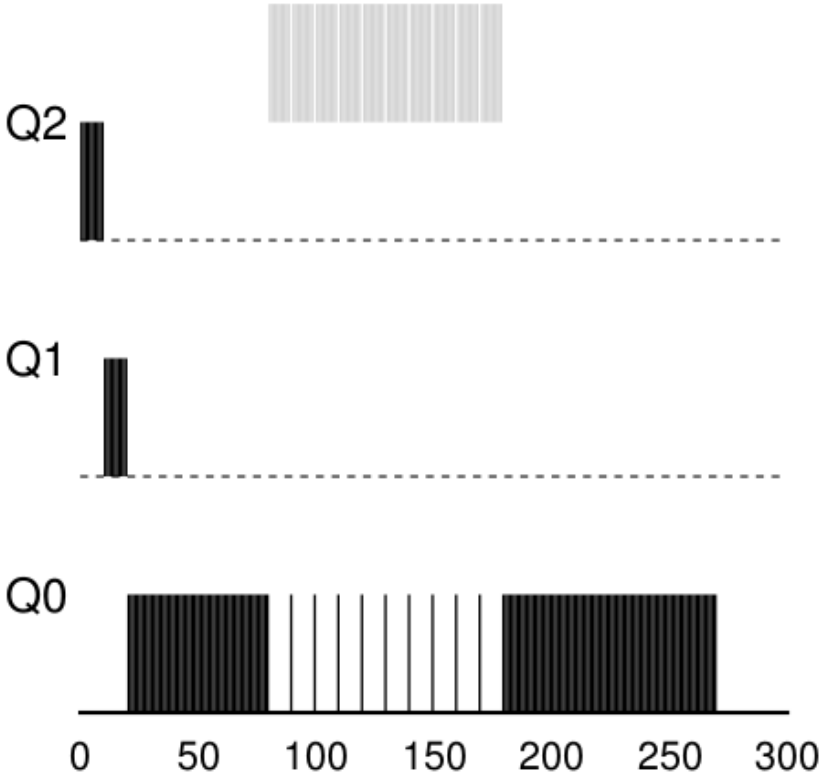

Sin protección de engaño

B monopoliza la CPU

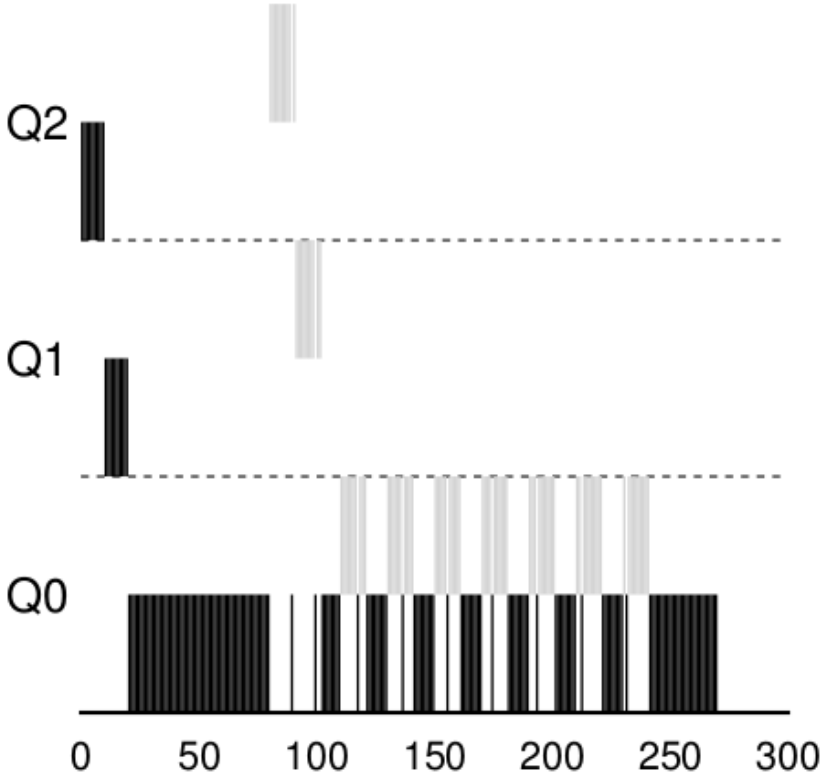

Con protección de engaño

B no puede monopolizar la CPU

Variaciones habituales

Hay múltiples variantes sobre MLFQ:

- Organización de colas por clases, para distintos tipos de tareas
  - Tareas de kernel, Procesos de usuario, Tareas de tiempo real, Trabajos por lotes (batch)
- Número de colas, cuantos e intervalos de boosting:
  - Solaris: 60 colas para la clase Time Sharing, con cuantos variando de 20ms a 100ms, y Priority Boost en intervalos de 1s
- Mecanismos de cambio prioridad
  - FreeBSD: uso de formulas, asignación de prioridad en función del tiempo de CPU y con decaimiento del tiempo de CPU en lugar de Boosting.
  - Solaris: mecanismo de cambio configurable por el administrador del sistema (tablas en ficheros de configuración).
- Admitir consejo de los usuarios para modificar las prioridades
  - Llamada al sistema `nice` en UNIX

MLFQ: estructura ejemplo

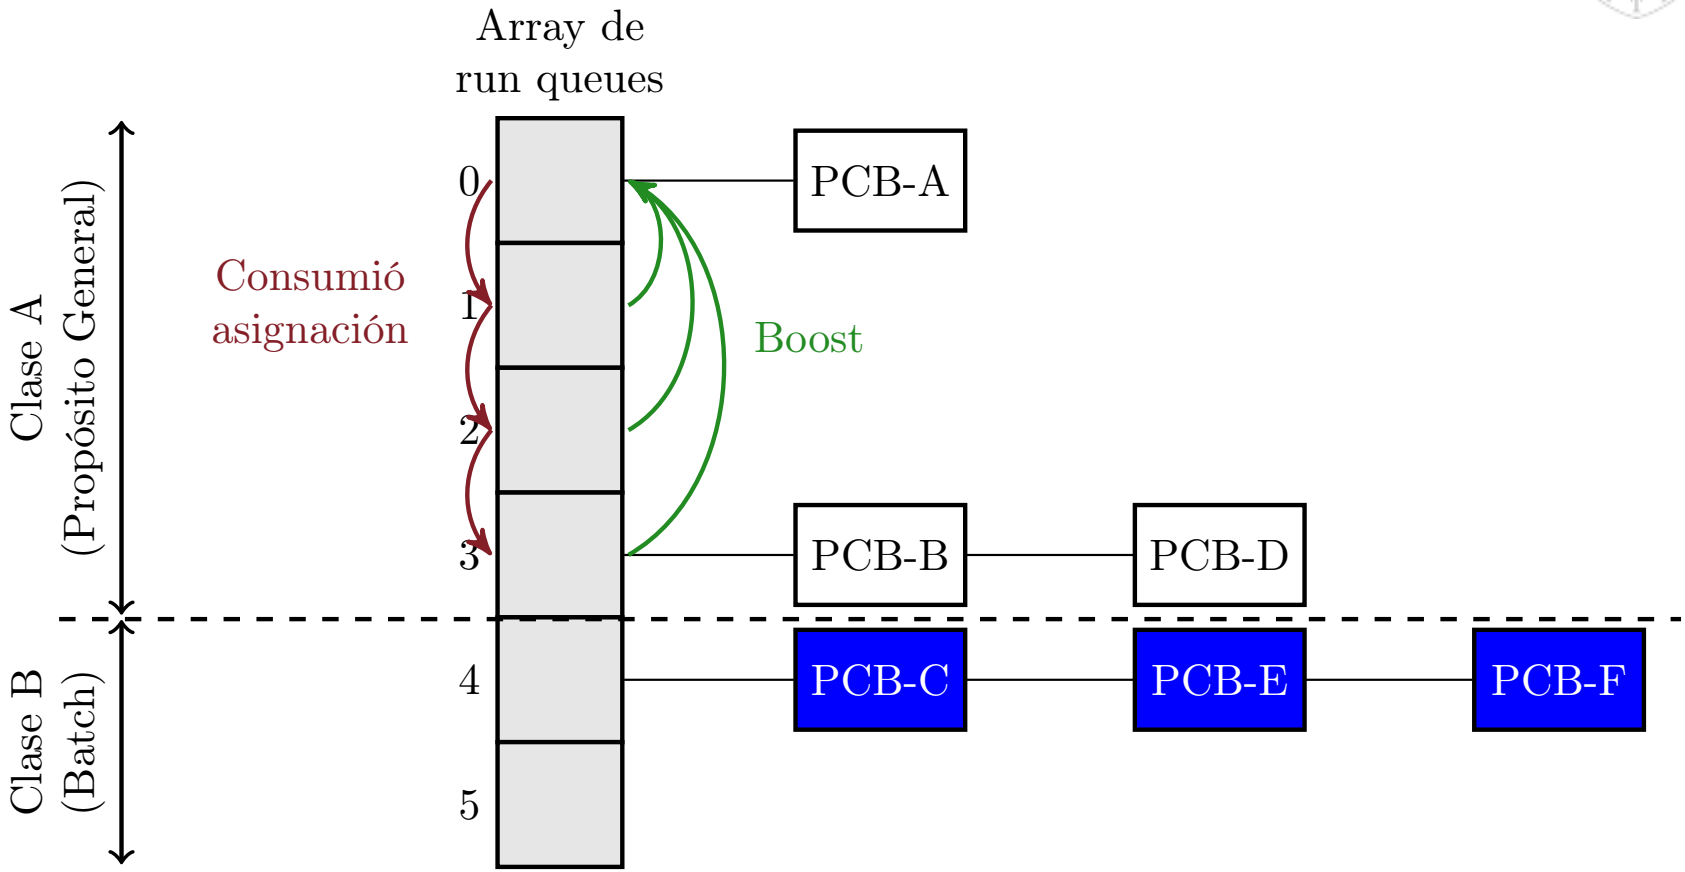

Agenda

Objetivos

Objetivos del reparto equitativo (fair):

- No optimizar el tiempo de ejecución o el de respuesta
- Tratar de garantizar un reparto equitativo
  - Que cada trabajo obtenga un cierto porcentaje de uso de CPU
  - Los porcentajes se fijan por tipo de trabajo, prioridad, etc

Claves:

- ¿Como podemos diseñar un planificador que garantice un reparto equitativo?
- ¿Cuáles son los mecanismos clave para ello?
- ¿Son efectivos y eficientes?

Concepto básico: Tickets

Tickets

La cantidad de tickets que tiene un proceso representa la porción de CPU que le corresponde.

Ejemplo:

Supongamos un sistema con dos procesos, A y B, en el que A tiene 75 tickets y B tiene sólo 25. En este caso el reparto de CPU deseado sería:

- A: $\frac{75}{75+25} \cdot 100 = 75\%$ de CPU
- B: $\frac{25}{75+25} \cdot 100 = 25\%$ de CPU

Planificador por Lotería

- Conoce el número total de tickets del sistema (N)
- Los procesos se ordenan por número de tickets, asignándoles los números de lotería. En nuestro ejemplo:
  - A con 75 tickets, números del 0 al 74
  - B con 25 tickets, números del 74 al 99
- Periódicamente (*time slice*) se saca un número aleatorio en $[0, N-1]$.
- Se cede la CPU al proceso que tenga asignado ese número

```
// numero aleatorio del ganador
int winner = getrandom(0, totaltickets);
int counter = 0;
node_t *current = head;
while (current) {
    counter = counter + current->tickets;
    if (counter > winner)
        break;
    current = current->next;
}
// Current queda apuntando al ganador
```

Ejemplo:

Planificación en 20 *time slices* consecutivos de dos procesos: A con 75 tickets y B con 25 tickets:

63	85	70	39	76	17	29	41	36	39	10	99	68	83	63	62	43	0	49	49
A		A	A		A	A	A	A	A	A		A		A	A	A	A	A	A
	B			B							B		B						

Resultado:

- B ejecuta $4/20 = 20\%$, inferior al 25% deseado.
- Carácter aleatorio hace que no se alcance la equitatividad perfecta con trabajos cortos
- La equitatividad mejora conforme aumenta la longitud de las tareas.

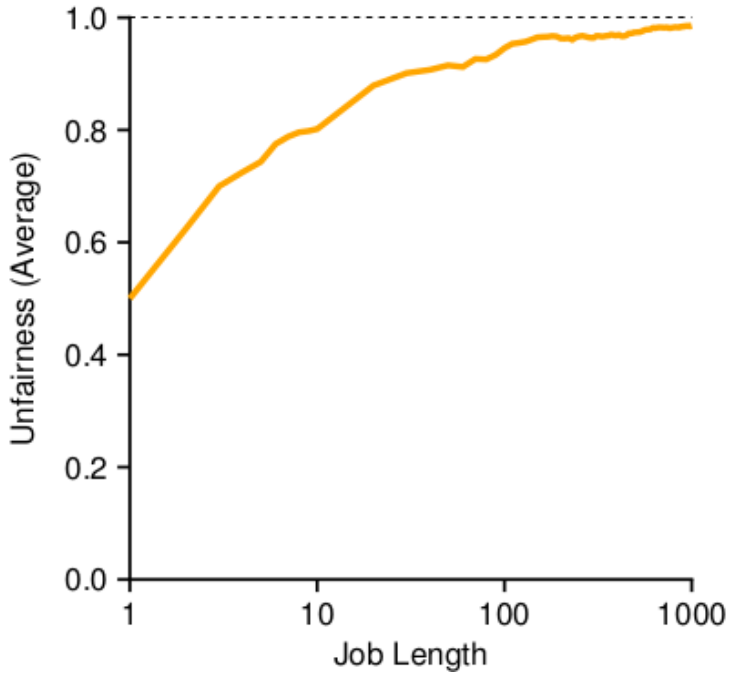

Problema inherente: ¿Cómo repartir los tickets?

Planificación equitativa determinista

Planificador de zancada (stride), propuesto por Waldspurger

- A cada tarea se le asigna una *zancada*, invérsamente proporcional al número de tickets que tiene asignados (más tickets, más prioridad, menor *zancada*)
- Para cada tarea se lleva la cuenta de sus *pasos*
- Cada vez que una tarea ejecuta se incrementan sus *pasos* en una cantidad igual a su *zancada*
- Se planifica siempre la tarea con menor número de *pasos*

Implementación muy sencilla también:

```
current = remove_min(queue);      //pick client with minimum pass
schedule(current);                //use resource for quantum
current->pass += current->stride;//compute next pass using stride
insert(queue, current);           //put back into the queue
```

Ejemplo:

Tareas: A, B y C; con 100, 50 y 250 tickets (total 400 tickets).
Zancada(X) = 10000 / Tickets(X). El resultado sería:

Pasos(A) (zancada=100)	Pasos (B) (zancada=200)	Pasos(C) (zancada=40)	Ejecuta
0	0	0	A
100	0	0	B
100	200	0	C
100	200	40	C
100	200	80	C
100	200	120	A
200	200	120	C
200	200	160	C
200	200	200	...

A: $2/8 = 100/400 = 25\%$, B: $1/8 = 50/400 = 12.5\%$,
C:$5/8 = 250/400 = 62.5\%$

- Planificador de lotería $\rightarrow$ equitatividad con el tiempo
- Planificador de zancada $\rightarrow$ equitatividad al final del ciclo

Completely Fair Scheduler (CFS)

- Planificación de tareas de tiempo compartido en Linux 2.6.23+
- Objetivos
  - Aproximar planificación completamente equitativa
  - Proporcionar buenos tiempos de respuesta
  - Optimizar al máximo el tiempo de planificación, que escale bien.
    - Cola de planificación implementada como un *árbol* balanceado
  - Soportar niveles de prioridad
    - 100 para procesos real-time (RR y FIFO)
    - 40 para procesos normales (CFS)
- Consultar código en:
  `https://code.woboq.org/linux/linux/kernel/sched/fair.c.html`

CFS: Conceptos básicos

- Un contador de tiempo virtual (*vruntime*) para cada tarea
- Al planificar se escoge siempre la tarea con menor *vruntime*
  - Es la que se merece más la CPU en ese momento
- Se asigna un tiempo variable a las tareas
  - *sched_latency_ns*: unidad de tiempo que se reparte equitativamente entre todas las tareas listas
  - Se asigna una fracción **proporcional** al *peso* de la tarea.
    - Es una medida de la prioridad de la tarea
- El contador *vruntime* de cada tarea se incrementa en una cantidad **inversamente proporcional** al *peso* de la tarea
  - El *vruntime* de las tareas irá incrementándose al mismo ritmo

CFS: Pesos y nice

La prioridad/peso se fija en función del valor *nice*

- Inversamente proporcional al nice (n): $W = K/\alpha^n$
  - Una tarea *amable* demanda poca CPU
- Objetivo: dos procesos con $\Delta\text{nice} = 1$ queremos que tengan un $\Delta T_{\text{CPU}} = 10\%$

$$T_a = \frac{K/\alpha^n}{K/\alpha^n + K/\alpha^{n+1}} = \frac{\alpha}{\alpha+1}$$

$$T_b = \frac{K/\alpha^{n+1}}{K/\alpha^n + K/\alpha^{n+1}} = \frac{1}{\alpha+1}$$

$$T_a - T_b = \frac{\alpha-1}{\alpha+1} = 0.1 \rightarrow \alpha = 1.222222...$$

El kernel de Linux aproxima a $\alpha = 1.25$ ($\Delta T_{CPU} \approx 11\%$), que es representable de forma exacta en punto fijo, y redondea los pesos para minimizar el error de la inversa ($M/1.25^n$) con aritmética de punto fijo.

CFS: Pesos y nice

El peso se fija en función del valor *nice*: $W = 1024/1.25^{nice}$

```
const int sched_prio_to_weight[40] = {
 /* -20 */     88761,     71755,     56483,     46273,     36291,
 /* -15 */     29154,     23254,     18705,     14949,     11916,
 /* -10 */      9548,      7620,      6100,      4904,      3906,
 /*  -5 */      3121,      2501,      1991,      1586,      1277,
 /*   0 */      1024,       820,       655,       526,       423,
 /*   5 */       335,       272,       215,       172,       137,
 /*  10 */       110,        87,        70,        56,        45,
 /*  15 */        36,        29,        23,        18,        15,
};
```

- Consultar tablas en:
  `https://code.woboq.org/linux/linux/kernel/sched/core.c.html#7089`

CFS: ejemplo 1

- 2 tareas intensivas en CPU, una con nice 0 y otra con 3
- *sched_lantency* de 24ms
- El tiempo de CPU se reparte proporcionalmente al peso:

$$T_{CPU}(x) = sched\_latency \cdot \frac{peso(x)}{\sum_{i=0}^{n} peso(i)}$$

- El *vruntime* se incrementaría para cada proceso según:

$$\Delta \text{vruntime}_i = \frac{peso_{nice=0}}{peso(i)} \cdot \Delta \text{runtime}_i = \frac{1024}{peso(i)} \cdot \Delta \text{runtime}_i$$

Al ser intensivas en CPU, asumimos $\Delta runtime_i = T_{\text{CPU}}(i)$:

Tarea	nice	Peso	T_{CPU} (ms)	% CPU	Δvruntime(ms)
A	0	1024	15.855484	66.06	15.855484
B	3	526	8.144516	33.93	15.855484

CFS: ejemplo 1

Ejemplo con el planificador CFS

```
> taskset -c 0 dd if=/dev/zero of=/dev/null &
> taskset -c 0 dd if=/dev/zero of=/dev/null &
> top
  PID USER      PR  NI    VIRT    RES    SHR S  %CPU  %MEM     TIME+ COMMAND
22548 christi+  20   0    7828    744    680 R  49.5   0.0   0:04.12 dd
22513 christi+  20   0    7828    740    676 R  49.2   0.0   0:06.23 dd
  ...
> sudo renice 3 22513
> top
  PID USER      PR  NI    VIRT    RES    SHR S  %CPU  %MEM     TIME+ COMMAND
22548 christi+  20   0    7828    744    680 R  65.8   0.0   0:41.23 dd
22513 christi+  23   3    7828    740    676 R  33.2   0.0   0:34.67 dd
  ...
```

CFS: ejemplo 2

3 tareas, con valores de nice 0, 0 y 3, y *sched_lantency* de 24ms

Tarea	nice	Peso	T_{CPU} (ms)	% CPU	Δvruntime(ms)
A	0	1024	9.547785	39.78	9.547785
B	0	1024	9.547785	39.78	9.547785
C	3	526	4.904429	20.43	9.547785

Ejemplo con el planificador CFS

```
> taskset -c 0 dd if=/dev/zero of=/dev/null &
> taskset -c 0 dd if=/dev/zero of=/dev/null &
> taskset -c 0 dd if=/dev/zero of=/dev/null &
> top
  PID USER      PR  NI    VIRT    RES    SHR S  %CPU  %MEM     TIME+ COMMAND
27540 christi+  20   0    7828    744    680 R  33.2   0.0   0:54.70 dd
27638 christi+  20   0    7828    684    620 R  33.2   0.0   0:51.17 dd
27643 christi+  20   0    7828    744    680 R  33.2   0.0   0:50.77 dd
  ...
> sudo renice 3 27643
> top
  PID USER      PR  NI    VIRT    RES    SHR S  %CPU  %MEM     TIME+ COMMAND
27638 christi+  20   0    7828    684    620 R 39.9   0.0   1:46.91 dd
27540 christi+  20   0    7828    744    680 R 39.5   0.0   1:50.42 dd
27643 christi+  23   3    7828    744    680 R 20.6   0.0   1:44.66 dd
  ...
```

CFS: planificaión rápida

- Siguiente hilo: el de menor `vruntime`
  - Hilos en un árbol balanceado *Red-Black*
  - Serie de videos en youtube sobre árboles red-black

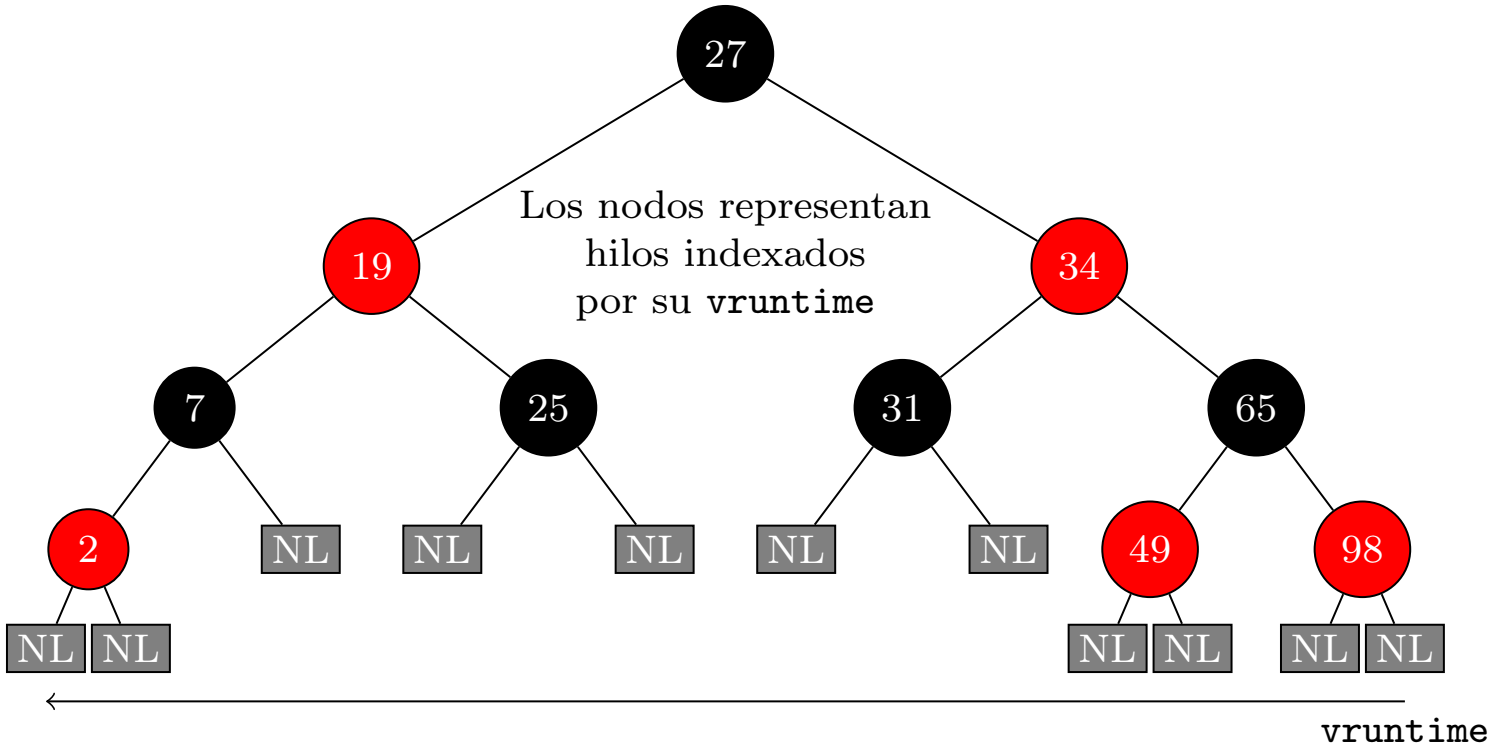

Comandos Linux de interés

Consultar la página de manual de los siguientes comandos:

- **nice**: ejecutar un comando con una prioridad entre -19 y 20
- **renice**: alterar la prioridad de un proceso en ejecución
- **taskset**: consultar o establecer la afinidad de CPU de un proceso o comando a ejectuar
- **sysctl**: consultar/modficar parámetros del kernel

sysctl

```
> sudo sysctl -A | grep sched
kernel.sched_child_runs_first = 0
kernel.sched_domain.cpu0.domain0.busy_factor = 64
...
kernel.sched_domain.cpu1.domain0.busy_factor = 64
kernel.sched_domain.cpu1.domain0.busy_idx = 2
...
kernel.sched_latency_ns = 12000000
kernel.sched_migration_cost_ns = 500000
kernel.sched_min_granularity_ns = 1500000
kernel.sched_nr_migrate = 32
kernel.sched_rr_timeslice_ms = 25
```

Agenda

Políticas de planificación

Las tareas en Linux son planificadas de acuerdo a dos parámetros:

- Su política/clase de planificación
- Su prioridad estática

Linux soporta actualment 6 polícas de planificación:

- `SCHED_DEADLINE` (no POSIX): Earliest Deadline First
- `SCHED_FIFO`: Fifo
- `SCHED_RR`: Round-Robin
- `SCHED_OTHER/SCHED_NORMAL`: CFS
- `SCHED_BATCH`: CFS
- `SCHED_IDLE`: CFS

Las clases `SCHED_FIFO`, `SCHED_RR` y `SCHED_DEADLINE` son para tareas de tiempo real

Documentación en man 7 sched

Prioridades estáticas

Conceptualmente hay 101 niveles, que de mayor a menor prioridad son:

- Tareas esporádicas con deadline, máxima prioridad (100)
  - `SCHED_DEADLINE`
- Tareas de tiempo real: prioridad estática 1-99
  - `SCHED_FIFO`
  - `SCHED_RR`
- Tareas de tiempo compartido (*time-sharing*): prioridad estática 0
  - `SCHED_OTHER/SCHED_NORMAL`
  - `SCHED_BATCH`
  - `SCHED_IDLE`

Conceptualmente el planificador tiene una cola por cada nivel de prioridad, y planifica la siguiente tarea del nivel más prioritario cuya cola no esté vacía

- Entre las tareas de tiempo compartido se asigna una prioridad *dinámica* a partir del valor de nice (-20 a +19)
- En el kernel las prioridades se mapean al rango 0-140, dónde 0 es la de mayor prioridad

Agenda

Objetivos adicionales

1. Garantizar un equilibrio de carga
   - Que no haya un procesador ocioso y otros con mucha carga
2. Tener en cuenta la afinidad de procesos y procesadores
   - Importante al replanificar un proceso (evitar migrar)
3. Tener en cuenta la compartición de datos entre procesos/hilos si hay varios nodos de memoria (NUMA)
   - Si dos hilos comparten memoria, probablemente sea bueno que compartan todo lo posible la jerarquía de memoria

Opción 1: cola de planificación única

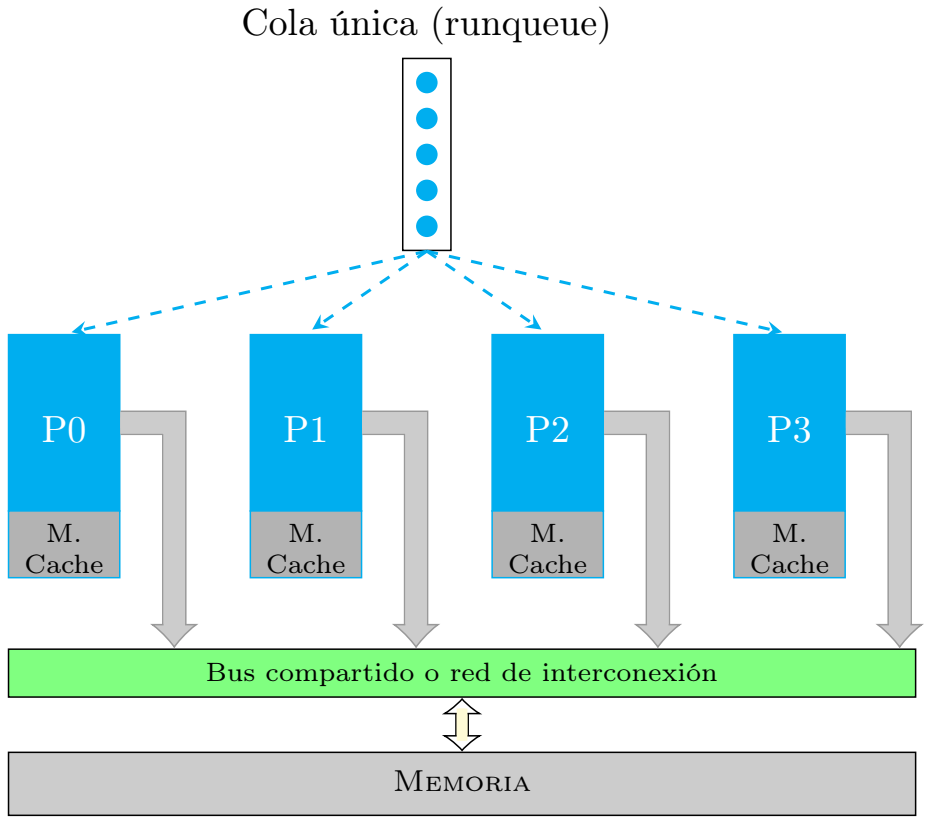

- Bueno para el balanceo de carga
- Malo para afinidad: los procesos pueden ir cambiando de CPU
- La cola es un cuello de botella: problema de escalabilidad

Opción 2: una cola de planificación por CPU

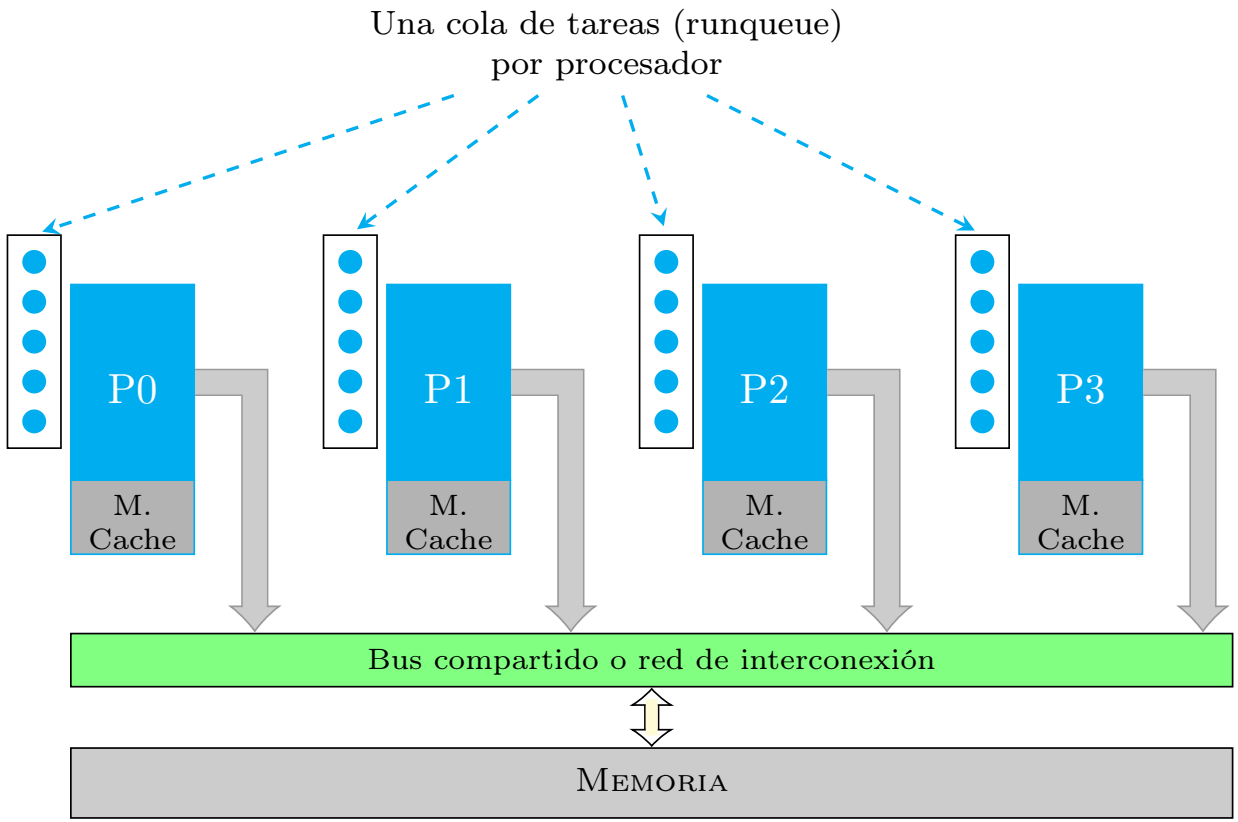

- Mayor escalabilidad
- Equilibrado de carga: periódico o bajo demanda
  - Considera qué procesos pueden/deben migrarse
  - Tiene en cuenta la afinidad
- Utilizada en la mayoría de los sistemas actuales